

Étude longitudinale de l'évolution d'une tumeur

Clément GREGOIRE

Marcel PECQUEUX

Médéric LAVIROTTE

1^{er} juillet 2026

Table des matières

1	Introduction	3
1.1	Données	3
I	Recalage	3
2	Méthodologie de recalage	3
2.1	Choix des transformations explorées	3
2.2	Pipeline de recalage	4
2.3	Paramètres retenus	4
3	Difficultés rencontrées	4
3.1	Lecture des volumes en 2D au lieu de 3D	4
3.2	Limitations du wrapping Python d'ITK	5
3.3	Instabilité de l'optimisation selon les paramètres	5
4	Résultats et analyse	5
4.1	Métriques quantitatives	5
4.2	Analyse	6
4.3	Méthode retenue	7
5	Conclusion	7
II	Segmentation	7
6	Méthodologie de la segmentation	8
6.1	Méthodes explorées	8
6.2	Seuillage Manuel avec composantes connexes	8
6.3	Region Growing	8
6.4	Seuillage automatique d'Otsu	8
7	Analyse et Comparaison des méthodes	9
7.1	Tableau comparatif des performances	9
7.2	Analyse Visuelle des résultats des méthodes	10
7.3	Analyse et critique des résultats	10
8	Résultats et Conclusion	11
8.1	Choix de la méthode de segmentation	11
8.2	Paramètres retenus	11

III	Visualisation des changements	12
9	Méthodologie	12
9.1	Visualisation 2D par coupes	12
9.2	Visualisation 3D interactive	12
10	Résultats	12
11	Analyse	13
12	Conclusion	13

1 Introduction

Ce projet a pour objectif de réaliser le suivi des changements d’une tumeur à partir de deux acquisitions IRM (`case6_gre1.nrrd` et `case6_gre2.nrrd`) effectuées sur un même patient à des dates différentes. Cette section du rapport présente la première étape du pipeline : le **recalage** (*registration*) des deux volumes, c’est-à-dire l’alignement géométrique de la seconde acquisition (*moving image*) sur la première (*fixed image*), condition nécessaire pour pouvoir ensuite comparer correctement les deux tumeurs segmentées.

1.1 Données

Les deux volumes fournis sont des images IRM 3D au format NRRD, de dimensions $256 \times 256 \times 176$ voxels, encodées en **unsigned short**. Les en-têtes indiquent un espace **left-posterior-superior** avec une matrice de directions non triviale (permutation/rotation des axes), ce qui a nécessité une attention particulière lors de la lecture et de l’affichage (voir section 3).

Première partie

Recalage

2 Méthodologie de recalage

2.1 Choix des transformations explorées

Trois familles de transformations géométriques globales ont été implémentées et comparées, classées par nombre de degrés de liberté (DOF) croissant :

Transformation	DOF	Corrige
Translation	3	Décalage de position uniquement
Rigide (VersorRigid3D)	6	+ rotation
Affine	12	+ échelle et cisaillement

TABLE 1 – Transformations explorées pour le recalage.

Une transformation **déformable** (B-Spline par exemple) a été délibérément exclue de l’exploration. Une telle transformation, en ajustant localement le champ de déformation, pourrait faire disparaître les différences entre les deux tumeurs en les déformant l’une vers l’autre — ce qui serait contre-productif dans une étude longitudinale où l’objectif est précisément de **pré-server et mesurer** l’évolution de la lésion entre les deux dates. Le choix s’est donc porté sur des transformations globales, qui réalignent l’anatomie du patient (position de la tête dans le scanner) sans déformer la tumeur elle-même.

Note sur le choix **VersorRigid3D** plutôt qu’**Euler3D**

Pour la transformation rigide, deux paramétrisations sont usuellement disponibles dans ITK : **Euler3DTransform** (3 angles de rotation) et **VersorRigid3DTransform** (rotation paramétrée par un quaternion/versor). Le second a été retenu pour deux raisons : (i) l’espace des versors ne présente pas les singularités de type *gimbal lock* des angles d’Euler, ce qui rend l’optimisation par descente de gradient plus stable, et (ii) seule cette paramétrisation est compatible avec **CenteredTransformInitializer** dans la distribution ITK Python utilisée (voir section 3).

2.2 Pipeline de recalage

Pour chaque méthode, le pipeline suivant est appliqué :

1. **Initialisation** par alignement des centres de masse (centres de gravité des intensités) des deux volumes. Pour la transformation rigide, `CenteredTransformInitializer` (mode `Moments`) est utilisé nativement. Pour la translation et l’affine, le même calcul est reproduit manuellement (voir section 3).
2. **Optimisation multi-résolution** à 3 niveaux (facteurs de sous-échantillonnage 4, 2, 1 et lissage gaussien $\sigma = 2, 1, 0$ voxels) : le recalage est d’abord effectué sur une version grossière et floutée de l’image (rapide, robuste aux optima locaux), puis affiné progressivement jusqu’à la pleine résolution.
3. **Métrique de similarité** : information mutuelle de Mattes (`MattesMutualInformationImageToImageMetricv2`, 50 *bins* d’histogramme), choisie car robuste aux différences d’intensité/contraste entre les deux acquisitions IRM (contrairement à une simple différence de pixels, qui suppose des intensités directement comparables).
4. **Optimiseur** : descente de gradient à pas adaptatif (`RegularStepGradientDescentOptimizersv4`), avec un échantillonnage stochastique de 20 % des voxels à chaque itération pour accélérer le calcul de la métrique.

2.3 Paramètres retenus

Paramètre	Valeur
<code>LearningRate</code>	1.0
<code>MinimumStepLength</code>	10^{-4}
<code>RelaxationFactor</code>	0.7
<code>NumberOfIterations</code> (max)	500
<code>NumberOfHistogramBins</code>	50
<code>MetricSamplingPercentage</code>	0.20
Niveaux multi-résolution	3 (facteurs 4/2/1)

TABLE 2 – Paramètres de l’optimiseur et de la métrique.

Mise à l’échelle des paramètres (*optimizer scales*)

Un point technique déterminant pour la qualité du recalage rigide et affine est la **mise à l’échelle relative des paramètres** de la transformation. Pour `VersorRigid3D`, les 3 premiers paramètres (rotation, sans unité, de norme proche de 0 pour de petites rotations) et les 3 derniers (translation, en millimètres, pouvant atteindre plusieurs dizaines de mm) ont des ordres de grandeur très différents. Sans pondération explicite, l’optimiseur, qui applique le même pas à tous les paramètres, sous-pondère fortement la rotation par rapport à la translation. Un facteur d’échelle de 1/1000 a été appliqué aux paramètres de translation (relativement aux paramètres de rotation/matrice) pour équilibrer leur contribution au gradient. C’est ce réglage qui a permis de débloquer la convergence de la méthode rigide (voir discussion des résultats, section 4).

3 Difficultés rencontrées

3.1 Lecture des volumes en 2D au lieu de 3D

Une première version du code de recalage, basée sur une initialisation fournie en début de projet, déclarait les images comme étant en dimension 2 (`itk.Image[itk.US, 2]`), alors que les

en-têtes NRRD indiquent explicitement `dimension: 3` avec des tailles $256 \times 256 \times 176$. Cette incohérence a été détectée car le volume recalé résultant apparaissait comme une fenêtre entièrement noire lors de la visualisation VTK — le volume produit n’avait pas la bonne géométrie. La correction a consisté à généraliser l’ensemble du pipeline (lecture, transformation, écriture) à la dimension 3.

3.2 Limitations du wrapping Python d’ITK

La distribution `itk` pré-compilée pour Python n’expose qu’un sous-ensemble limité des combinaisons (transformation, type d’image) du C++ sous-jacent, afin de limiter la taille du paquet. Deux conséquences concrètes ont été rencontrées :

- `CenteredTransformInitializer` n’est pas disponible pour `Euler3DTransform` avec des images en pixels `float` — seule la paramétrisation `VersorRigid3DTransform` est supportée. D’où le choix, documenté plus haut, d’utiliser cette dernière.
- `CenteredTransformInitializer` n’est pas non plus disponible pour `AffineTransform` en dimension 3 (seules les versions 2D de `MatrixOffsetTransformBase` le sont). L’initialisation par centre de masse a donc dû être reproduite manuellement pour cette transformation : la matrice est initialisée à l’identité (`SetIdentity`), le centre de rotation est fixé au centre de masse de l’image fixe, et la translation initiale au vecteur reliant les deux centres de masse.

Cette limitation illustre une difficulté pratique de l’écosystème ITK Python : le comportement attendu d’après la documentation C++ n’est pas toujours disponible tel quel, et nécessite soit un contournement applicatif (notre choix ici), soit une recompilation locale d’ITK avec les options de wrapping étendues.

3.3 Instabilité de l’optimisation selon les paramètres

Les tout premiers essais de recalage rigide et affine donnaient des résultats nettement moins bons que ceux présentés en section 4 (NCC négatif, pire que sans recalage). L’origine du problème était double :

- l’absence de mise à l’échelle des paramètres de l’optimiseur (`OptimizerScales`), qui faisait que la rotation et l’échelle/ cisaillement (paramètres de faible amplitude) étaient quasiment ignorés par rapport à la translation (paramètres de grande amplitude en mm) ;
- un `LearningRate` initial trop élevé (4.0), qui faisait « sauter » l’optimiseur autour du minimum sans jamais s’y stabiliser, provoquant un arrêt prématuré sur un mauvais point dès les premières itérations.

Le réglage de ces deux points (ajout des `OptimizerScales`, réduction du `LearningRate` à 1.0 et augmentation du `RelaxationFactor` à 0.7) a permis de stabiliser la convergence de la méthode rigide. Le détail de ce qui reste problématique pour la translation et l’affine est discuté en section 4.

4 Résultats et analyse

4.1 Métriques quantitatives

Pour évaluer objectivement la qualité de chaque recalage, deux métriques sont calculées entre l’image fixe et l’image mobile recalée, sur le champ de vue commun :

- **MSE** (*Mean Squared Error*) : moyenne des carrés des différences d’intensité. Plus bas = meilleur alignement.
- **NCC** (*Normalized Cross-Correlation*) : corrélation normalisée entre les intensités, entre -1 et 1. Plus proche de 1 = meilleur alignement.

Une valeur de référence (*baseline*), calculée **sans aucun recalage**, permet de quantifier l'apport (ou non) de chaque méthode.

Méthode	MSE	NCC	Temps (s)	Itérations
Baseline (sans recalage)	39 167.10	0.5364	—	—
Translation	106 709.16	−0.3898	11.7	236
Rigide	10 509.42	0.8807	14.7	235
Affine	114 887.00	−0.3857	142.5	1500

TABLE 3 – Comparaison quantitative des méthodes de recalage.




FIGURE 1 – Comparaison visuelle avant/après recalage rigide (coupe axiale centrale) et damier (checkerboard) fixed/moving recalée.




FIGURE 2 – Courbes de convergence de l'optimiseur (valeur de la métrique de Mattes par itération) pour les trois méthodes.

4.2 Analyse

Le résultat le plus marquant est le contraste très net entre la méthode **rigide**, qui converge proprement vers un excellent alignement (NCC= 0.88, arrêt par convergence du gradient après 36 itérations réelles), et les méthodes **translation** et **affine**, qui aboutissent toutes deux à un résultat *pire que l'absence de recalage* (NCC négatif, alors que la baseline sans recalage donne NCC= 0.54).

Translation (3 DOF) — sous-paramétrée. Avec seulement 3 degrés de liberté, ce modèle ne peut corriger qu’un décalage de position, pas une rotation. Si le déplacement réel de la tête du patient entre les deux acquisitions IRM comporte une composante de rotation — ce qui est physiquement très plausible —, la translation seule ne peut pas l’absorber et l’optimiseur converge vers un minimum local correspondant à un mauvais appariement de structures anatomiques. L’arrêt après seulement 14 itérations réelles avec un gradient déjà quasi nul confirme un blocage précoce dans un minimum local proche du point de départ, plutôt qu’une réelle convergence vers le minimum global.

Affine (12 DOF) — sur-paramétrée et instable. À l’inverse, le modèle affine, avec 12 paramètres mélangeant rotation, échelle et cisaillement dans une même matrice 3×3 , définit un espace de recherche beaucoup plus vaste et non convexe pour l’information mutuelle. Le fait que l’optimisation utilise l’intégralité des 500 itérations autorisées sans jamais déclencher l’arrêt par convergence (*step too small*) indique qu’elle **n’a jamais convergé** — elle continue d’errer dans l’espace des paramètres jusqu’à la limite arbitraire d’itérations, ce qui est cohérent avec le résultat final dégradé. Ce phénomène est documenté dans la littérature sur le recalage par information mutuelle : sans contrainte ou initialisation plus fine, la matrice affine peut dériver vers des solutions quasi-singulières qui maximisent artificiellement (ou dégradent) la métrique sans correspondre à un alignement anatomique valide.

Rigide (6 DOF) — bien adapté au problème physique. Le bon comportement de la méthode rigide s’explique par l’adéquation entre le modèle et la nature réelle de la différence entre les deux acquisitions : deux IRM du même patient à des dates différentes ne diffèrent, en première approximation, que par la **pose** de la tête dans le scanner (position + orientation), pas par un changement d’échelle ou un cisaillement de l’anatomie. Un modèle à 6 DOF, ni trop ni trop peu contraint pour ce problème, permet à l’optimiseur de converger proprement (arrêt par *step too small*, signe d’une convergence atteinte et non d’une limite arbitraire).

4.3 Méthode retenue

Au vu de ces résultats, la transformation **rigide** (`VersorRigid3DTransform`) est retenue pour la suite du pipeline (segmentation et comparaison des tumeurs). Elle est la seule des trois méthodes testées à améliorer significativement l’alignement par rapport à l’absence de recalage (NCC : $0.54 \rightarrow 0.88$), et son adéquation au problème physique (changement de pose du patient entre deux acquisitions) est cohérente avec son comportement de convergence observé.

5 Conclusion

Cette étape de recalage a permis de mettre en évidence, par une comparaison systématique et quantifiée de trois familles de transformations, que le modèle rigide est le mieux adapté à l’alignement de deux IRM du même patient à des dates différentes. Les méthodes à plus faible (translation) ou plus forte (affine) flexibilité donnent toutes deux des résultats dégradés, pour des raisons distinctes mais cohérentes avec la théorie de l’optimisation non convexe (sous-paramétrisation *vs* instabilité d’un espace de recherche trop vaste). Le volume recalé par transformation rigide sert de base à l’étape suivante du pipeline.

Deuxième partie

Segmentation

6 Méthodologie de la segmentation

6.1 Méthodes explorées

Pour la partie segmentations de la tumeur, nous avons explorés en tout, trois méthodes que nous avons implémentés avant de les avoir comparé à partir d'une donnée unique. Toute les méthodes sont ainsi partie de l'image `case6_gre1.nrrd` avec toute le même point de départ ou seed, le voxel (90, 80, 47) située à l'intérieur de la tumeur.

Algorithme	Paramètre
Seuillage Manuel avec composantes connexes	seuil définit à 630
Region Growing	multiplicateur = 1.7, 3 itérations
Seuillage automatique d'Otsu	calculé automatiquement

TABLE 4 – Méthodes de segmentation explorées

Dans les trois cas, la segmentation est restreinte à la composante connexe contenant le seed, permettant ainsi d'isoler la tumeur des autre structures sans avoir à régler une région d'intérêt de manière manuelle. L'espacement des voxels étant de $1 \times 1 \times 1$ mm, le volume en mm^3 est directement égale au nombre de voxels segmentés.

6.2 Seuillage Manuel avec composantes connexes

Cette méthode un principe de seuillage global. En premier on décide de fixer un seuil arbitraire, selon une étude des résultats, dans le cadre de cette comparaison, le seuil équivaut à 630. Une fois le seuil définit, tout les pixels au-dessus du seuil donc 630 deviennent 1 cela signifie que le pixel est une tumeur potentielle, les autres deviennent 0 pour expliquer ce que c'est le fond. Pour éviter que des valeurs ne faisant pas partie de la tumeur soit utilisé, on utilise les composantes connexe, qui une fois lancé sur le seed, va ne garder que les pixels qui touche ce point et ainsi de suite. Tout ce qui n'a aucun chemin menant au point de départ, sont effacés.

6.3 Region Growing

Contrairement à la méthode de seuillage manuel, cette méthode est plus dynamique et local, le principe est le suivant : On part du seed, l'algorithme regarde tout les voisins du point auquel on se situe. Pour chacun des points, on regarde si son intensité est proche de la moyenne de la région sélectionnée, en se basant sur l'écart-type. Si c'est belle est bien le cas, le pixel est inclus comme partie de la tumeur.

Pour appliquer ce principe, on répète ces opérations pour 3 itérations au cours duquel l'écart-type multiplié par 1.7 et la moyenne s'ajuste par rapport au résultat de la dernière itération.

6.4 Seuillage automatique d'Otsu

Pour finir, l'algorithme d'Otsu va calculer le meilleur seuil en analysant l'historigramme des voxels. Son but est de chercher à séparer l'image en deux groupe :

$$\sigma_B^2(t) = w_0(t)w_1(t) [\mu_0(t) - \mu_1(t)]^2$$

Avec :

- t : le seuil testé
- $\sigma_B^2(t)$: la variance inter-classe représentant le score du seuil t
- $w_0(t)$: la proportion de voxels sur l'image qui se retrouve dans le fond
- $w_1(t)$: la proportion de voxels sur l'image qui se retrouve dans la tumeur
- $\mu_0(t)$: L'intensité moyenne des voxels du fond
- $\mu_1(t)$: L'intensité moyenne des voxels de la tumeur

Pour éviter de rater la tumeur à cause de la présence du noir de l'IRM, on utilise un Otsu en 2 étapes :

- **Etape 1** : On applique Otsu sur tous les voxels avec un seuil supérieur à 100 (468) pour séparer le cerveau complet du fond noir
- **Etape 2** : On applique un deuxième Otsu (seuil égal à 673) uniquement sur les pixels du cerveau pour séparer la tumeur du reste du tissu cérébral sain.

7 Analyse et Comparaison des méthodes

7.1 Tableau comparatif des performances

Le tableau suivant rassemble chacun des indicateurs obtenus pour chacune des méthodes de segmentation appliquées à l'acquisition T1, avec une seed identique située au coordonnée (90,80,47)

Méthodes	Volumes (mm^3)	Intensité Moyenne
Seuillage Manuel avec composantes connexes (seuil=360)	5707 mm^3	728.0
Region Growing	5896 mm^3	699.7
Seuillage automatique d'Otsu	5896 mm^3	705.5

TABLE 5 – Comparaison des méthodes de segmentation

7.2 Analyse Visuelle des résultats des méthodes




FIGURE 3 – Comparaison visuelle des trois méthodes de segmentations sur 5 niveau différents de la tumeur sur l’acquisition T1. De haut en bas : image , seuillage manuel (rouge), Region Growing (vert), Seuil automatique d’Otsu (bleu).

7.3 Analyse et critique des résultats

Seuillage Manuel avec composantes connexes : Une approche trop restrictive et dépendante d’un réglage arbitraire. L’intensité moyenne élevée, 728.0 démontre que cette méthode est trop conservatrice. En fixant arbitrairement le seuil à 630, seul le cœur de la tumeur est capturé, excluant ses bords plus diffus. Le protocole de seuillage manuel introduit un biais qui est inhérent au réglage manuel : la reproductibilité est tout simplement impossible car un changement d’acquisition comme celui T2 modifierait radicalement le volume final.

Region Growing : volume proche du manuel mai une extension fragile. Avec un volume de 5896 mm^3 et une intensité moyenne de 699.7, le Region Growing détecte légèrement plus que le seuillage manuel. Bien qu’elle soit légèrement supérieure au seuil manuel en terme de volume, la baisse de l’intensité moyenne montre que l’algorithme commence à intégrer des voxels au périphériques moins brillants. L’une des limites de cette méthode, c’est qu’elle est a une forte dépendance au choix du seed initial, un décalage d’un seul pixel au point de départ pourrait modifier toute la logique et dynamique de croissance rendant tout le traitement instable pour en faire une pipeline complètement automatisé.

Seuillage automatique Otsu : Le compromis le plus optimal parmi les 3 La méthode Otsu produit le volume le plus élevé 6980 voxels, ce qui représente +22% par rapport au seuillage manuel, avec une intensité moyenne de 705.5. Ceci confirme que mathématiquement que les voxels obtenus appartiennent bien aux bordures tumorales et non à du tissu sain. Enfin en retrouvant le seuil final , ≈ 572 , proche mais inférieur au seuil manuel (630), est calculé automatiquement à partir de la distribution des intensités : il est donc reproductible et non biaisé par l’opérateur.

Ce qui fait de cette méthode d'Otsu une méthode de segmentation qui garantit la reproductibilité, et l'automatisation.

8 Résultats et Conclusion

8.1 Choix de la méthode de segmentation

La méthode de **Seuillage automatique Otsu en 2 étapes** est la méthode que nous avons finalement retenue pour segmenter la tumeur sur les deux acquisitions (T1 et T2) pour la suite du pipeline, pour quatre raisons majeures :

1. Le volume de cette méthode est le plus élevé 6.980 mm^3 assurant ainsi, une meilleure capture des bords de la tumeur.
2. L'intensité moyenne de ce méthode, 705.5, valide le fait que la région segmentée reste dans la zone hyperintense caractéristique de la tumeur.
3. L'absence de biais à définir avec un calcul automatique du seuil, pour T1, ≈ 572 , proche du seuil manuel (630) ce qui valide l'approche, mais sans biais d'opérateur.
4. validation visuelle satisfaisante : contours nets, pas de débordement majeur sur le tissu sain (figure 3).

8.2 Paramètres retenus

Paramètre	Valeur
Seuil étape 1	468
Seuil étape 2	673
Facteur correctif	0.85
Seuil final retenu	≈ 572

TABLE 6 – Paramètres du seuillage d'Otsu retenu

Troisième partie

Visualisation des changements

9 Méthodologie

9.1 Visualisation 2D par coupes

Pour la visualisation 2D, on retrouve une grille de coupes axiales centrées sur la tumeur en tout 5 coupes espacées en tout de 6 voxels, qu'on va généré pour les deux acquisitions, avec le masque de segmentation superposés en transparence (rouge pour T1, bleu pour le T2). Les bornes d'intensité de chaque image sont fixées aux 1^{er} et 99^e percentiles des intensités non nulles, ce qui évite que quelques voxels extrêmes (artefacts, vaisseaux très brillants) ne saturent l'affichage et écrasent le contraste utile.

9.2 Visualisation 3D interactive

Dans une scène 3D interactive de VTK, on a la combinaison suivante :

- un **rendu volumique** du cerveau en transparence très faible, pour donner un contexte anatomique sans masquer la tumeur.
- une **reconstruction de surface** de chaque masque tumoral par l'algorithme de **Marching Cubes** précédée d'un lissage gaussien.

Les deux surfaces (T1 en rouge, T2 en bleu) ne sont jamais affichées simultanément : avec la touche Espace qui permet de passer de l'une à l'autre, ce qui facilite la comparaison directe de la forme et du volume sans superposition confuse. La touche S qui permet d'afficher ou de masquer le volume cérébral pour isoler la tumeur seule, et la caméra est pilotée par une paramétrisation sphérique (azimut, élévation et distance autour d'un centre fixe), contrôlable à la souris et au clavier.

10 Résultats



FIGURE 4 – Reconstruction 3D de la tumeur en T1 (rouge), avec le volume cérébral en transparence pour contexte anatomique.




FIGURE 5 – Reconstruction 3D de la tumeur en T2 (bleu), même point de vue que la figure précédente pour faciliter la comparaison

11 Analyse

Évolution du volume. Entre deux acquisitions notamment sur celle des figures précédentes ont va pourvoir voir, si le volume de la tumeur a augmenté, diminué ou tout simplement est resté stable. Ceci, va permettre de suggérer une progression de la la tumeur, une réponse au traitement ou une stabilité selon le cas.

Chevauchement spatial via Dice. Un coefficient de Dice de indique un chevauchement important ou faible entre les deux masques, ce qui traduit non seulement un changement de volume mais aussi, potentiellement, un déplacement ou un changement de forme de la lésion entre les deux dates.

Apport de la visualisation 3D par rapport aux métriques. Les métriques quantitatives, volume et Dice, résument l'évolution en quelques chiffres mais ne renseignent pas sur **où** et **comment** la tumeur a changé de forme. La reconstruction de surface 3D permet d'observer directement si la croissance est localisée ou diffuse, information que le Dice seul ne peut pas révéler.

12 Conclusion

La combinaison d'une visualisation 2D par coupes superposées et d'une reconstruction 3D interactive permet une lecture à la fois quantitative, avec le volume et Dice, et qualitative, avec les formes, de l'évolution tumorale entre les deux acquisitions.